PROYECTO 2 · DISEÑO GENERATIVO DE PERSONAJES

Puerto Prisma

Crear un universo que no existe

Generación de retratos con una DCGAN, experimentos controlados y evidencia de diversidad y similitud con los datos.

Jorge López · 221038
Ángel Herrarte · 22873

Universidad del Valle de Guatemala
Deep Learning 2026 · Docente: Kevin Recinos



Código, pesos y evidencias en GitHub

Un universo definido por sus retratos

Puerto Prisma

Ciudad imaginaria de comerciantes, inventores y exploradores. Retratos para un videojuego narrativo: vista frontal, colores planos, fondo blanco y rasgos simplificados.

Criterio visual: reconocer un rostro y variar cabello, forma facial y accesorios dentro de un estilo común.

Cartoon Set 10k

10 000 caricaturas por composición de piezas, de Google LLC; arte de Shiraz Fuman.

Datos: licencia CC BY 4.0. Sin fotos de personas reales. Originales RGBA 500 × 500; salida RGB 64 × 64 con transparencia sobre blanco y Lanczos. Sin recorte ni aumento.

Validación: 10 000 imágenes decodificables; 0 duplicados exactos a 64 × 64. Se conserva el origen de cada imagen y el SHA256 del archivo descargado.

Fuente y licencia: Google Cartoon Set

Copia de descarga: cgarciae / Hugging Face

El almacenamiento original devolvió 403; se usó una copia con integridad comprobada. Los vecinos mostrados se atribuyen al dataset.

DCGAN: una base simple y reproducible

Generador G

Ruido z: 100 × 1 × 1.
ConvTranspose: 512 -> 256 -> 128 -> 64 -> 3 canales.
Resoluciones: 4 -> 8 -> 16 -> 32 -> 64.
BatchNorm + ReLU; salida Tanh en [-1, 1].

Discriminador D

Imagen RGB 64 × 64.
Conv: 64 -> 128 -> 256 -> 512 -> 1 canal.
LeakyReLU (0.2); BatchNorm en bloques internos.
Salida: un logit, sin sigmoid en la pérdida.

BCEWithLogitsLoss: D distingue reales y falsas; G usa la pérdida no saturante con objetivo real. Adam: betas (0.5, 0.999), batch 128 y lr base 0.0002.
30 épocas por ejecución; Colab Tesla T4; checkpoint completo después de cada época.

Referencia de arquitectura: tutorial DCGAN de PyTorch

Elegimos DCGAN por su implementación explicable y su costo manejable a 64 × 64; mayor resolución no era necesaria para el alcance.

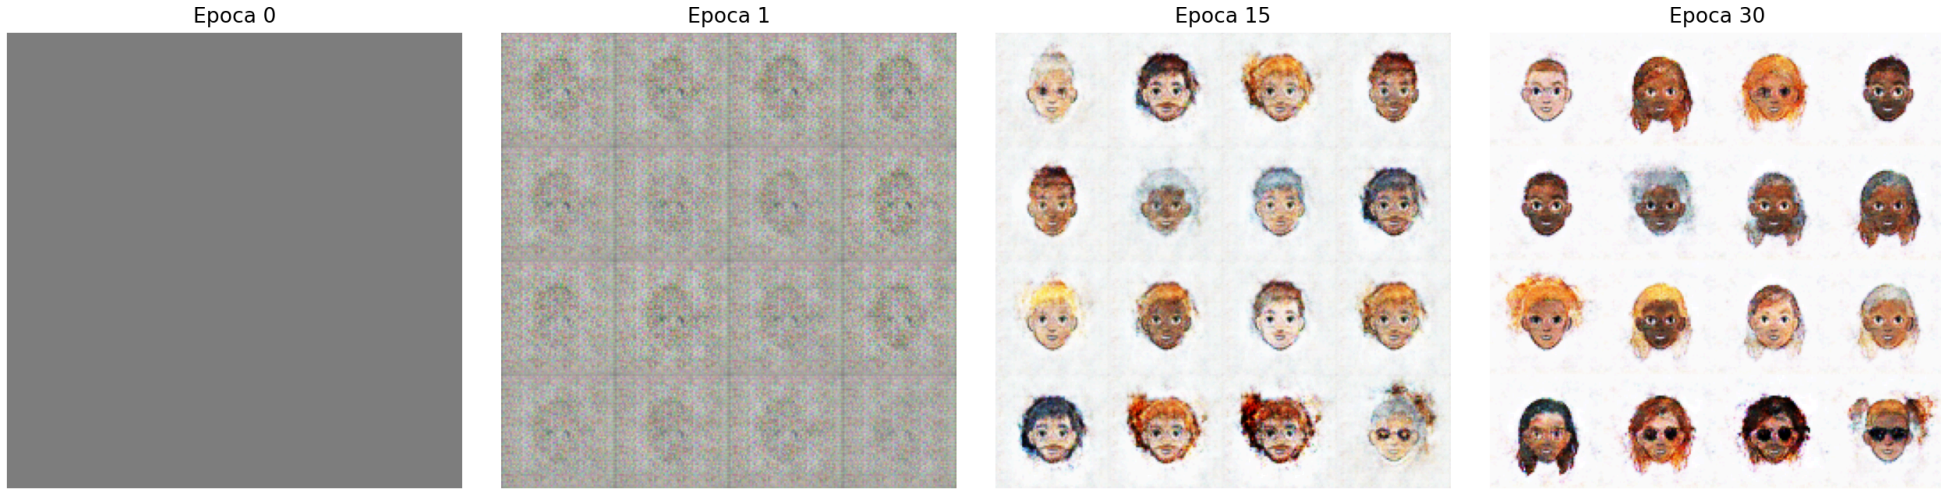
Tres ejecuciones; un cambio por experimento

Base	BCE no saturante	lr G = lr D = 0.0002
Pérdida	Etiqueta real D: 1.0 -> 0.9	Falsa D = 0; objetivo G = 1
Estabilización	lr D: 0.0002 -> 0.0001	lr G conserva 0.0002

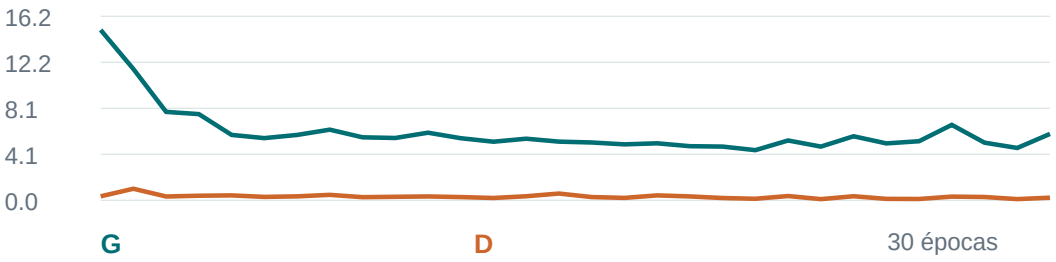
Controles: mismo dataset, arquitectura, semilla 2026, inicialización, batch 128, 30 épocas y orden de batches. Ruido fijo: 16 vectores, semilla 2027.
Cada experimento parte desde cero y se compara con la base; no combinamos ambos cambios.

Hipótesis registradas antes de entrenar. Una sola semilla limita las conclusiones; las pérdidas con etiquetas distintas no son directamente equivalentes.

Del ruido a rostros reconocibles



Pérdidas BCE · base



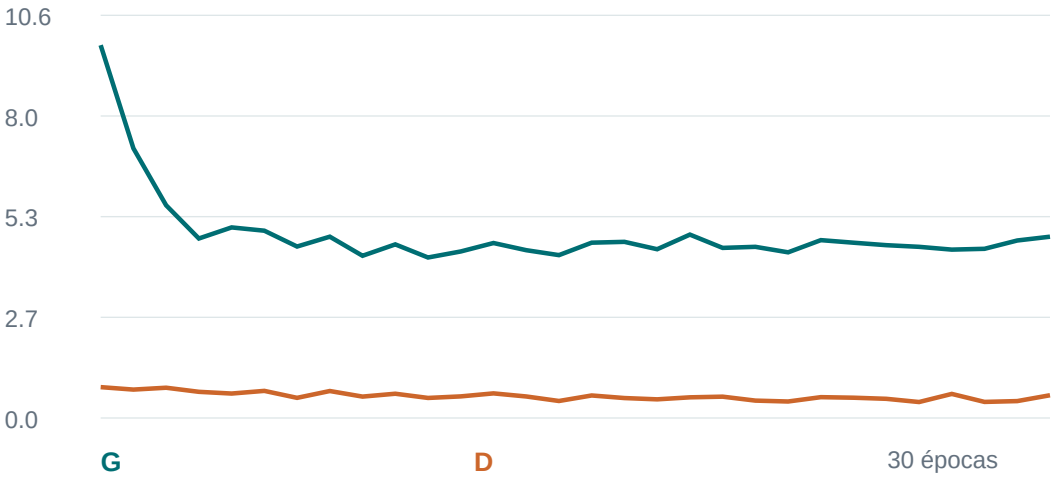
Mismos 16 vectores: aparecen rostros hacia época 15. A la 30: G = 5.853, D = 0.234 y D(fake) = 0.071; D domina, no es señal de éxito.
Persisten ruido y repetición de rasgos. No se ve colapso completo en esta rejilla; posible colapso parcial.

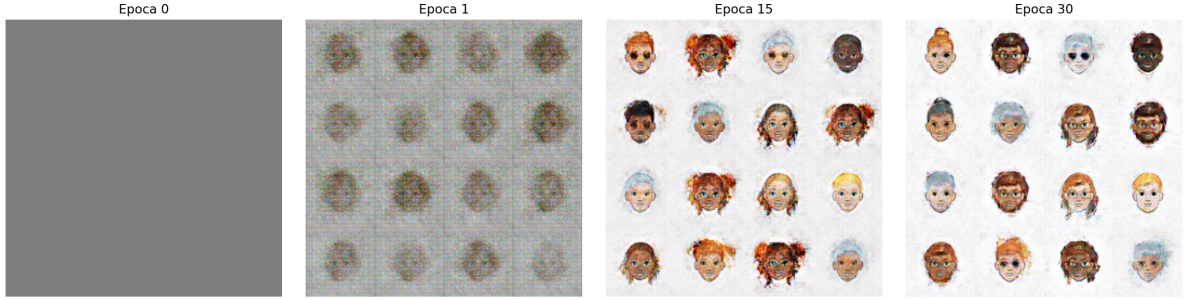
16 ejemplos no descartan memorización. El cuadro gris inicial corresponde al modelo sin entrenar. G y D no deben bajar juntas.

Pérdida: suavizado de etiquetas reales

Hipótesis previa: usar 0.9 en reales reduciría la confianza extrema de D y mejoraría calidad. Útil si la rejilla tiene menos artefactos y conserva rostros distintos, sin perder estructura.

Pérdidas BCE · experimento 03





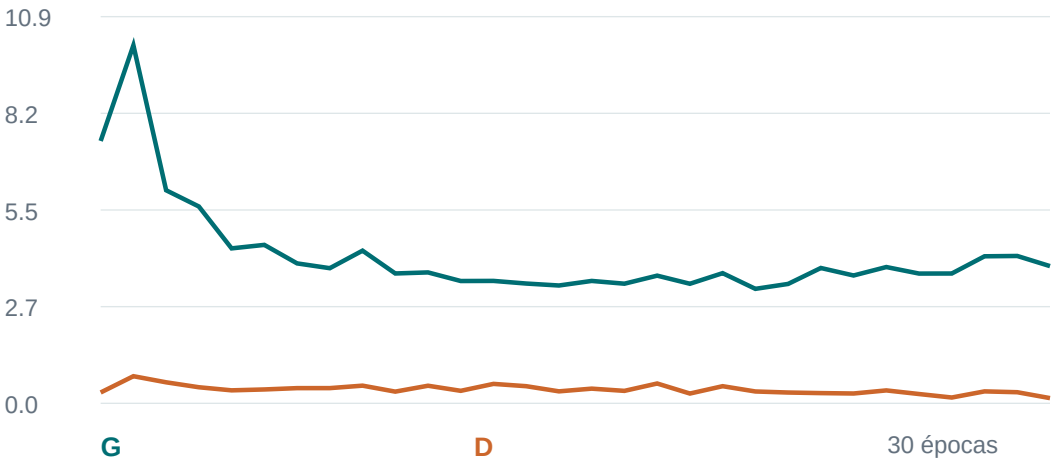
Época 30: G = 4.774; D = 0.599.
D(real) = 0.820; D(fake) = 0.079.
Menor confianza sobre reales, compatible con la etiqueta 0.9. Mejora visual mixta; D sigue separando falsas.

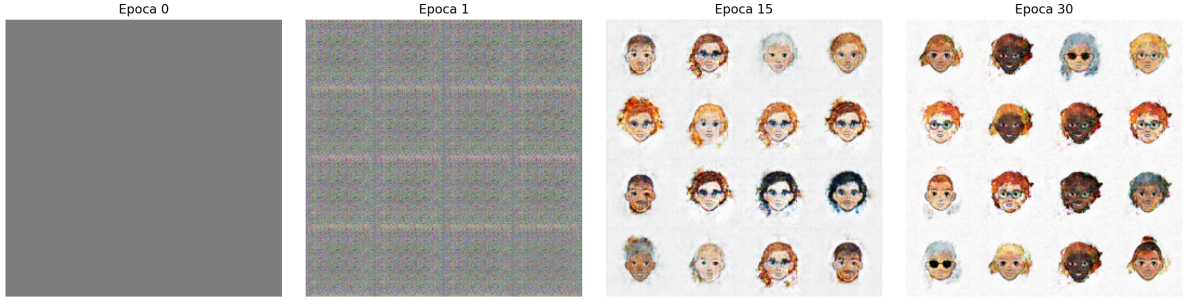
Resultado: la hipótesis de mejora visual no queda confirmada. La pérdida de D cambia de objetivo; no interpretamos su magnitud como calidad.

Estabilización: ralentizar las actualizaciones de D

Hipótesis previa: reducir lr D a 0.0001 daría a G oportunidad de aprender mejores rasgos. Útil si disminuyen artefactos y se mantiene diversidad, sin dominio persistente de D ni pérdida de discriminación.

Pérdidas BCE · experimento 04





Época 30: G = 3.884; D = 0.147.
D(real) = 0.935; D(fake) = 0.064.
D sigue dominando: no se resuelve el desequilibrio. Elegimos la época 15 por el equilibrio visual entre calidad y variedad.

La elección de época 15 es selección de checkpoint para la galería, no prueba de superioridad general. Más épocas no garantizaron mejor calidad.

Diez habitantes de Puerto Prisma



Ivo · ID 003

Mensajero



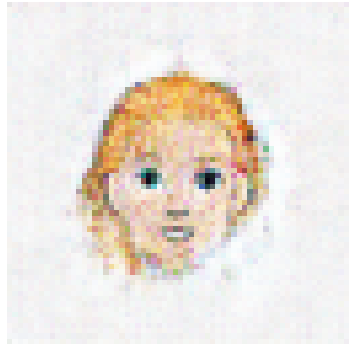
Ada · ID 005

Archivista



Nilo · ID 007

Explorador



Lía · ID 013

Cartógrafa



Vera · ID 016

Mediadora



Teo · ID 024

Inventor



Alma · ID 040

Navegante



Bruno · ID 093

Guardián



Sol · ID 120

Aprendiz



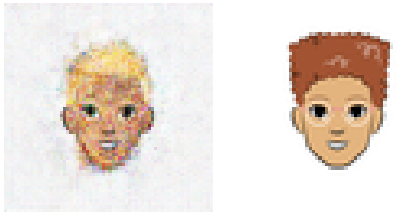
Rui · ID 163

Comerciante

Selección: 10 de 200 (5 %). Nombres y roles son autoría narrativa del equipo, no etiquetas predichas. PNG originales 64 × 64 sin retoques.

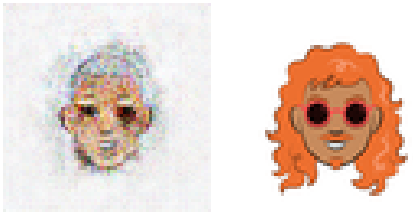
Cada personaje frente a su vecino más cercano

ID 003 · GAN / real



d coseno = 0.2660

ID 005 · GAN / real



d coseno = 0.3403

ID 007 · GAN / real



d coseno = 0.2883

ID 013 · GAN / real



d coseno = 0.2633

ID 016 · GAN / real



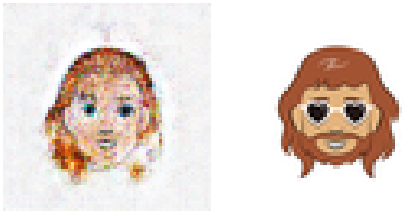
d coseno = 0.3074

ID 024 · GAN / real



d coseno = 0.2914

ID 040 · GAN / real



d coseno = 0.3047

ID 093 · GAN / real



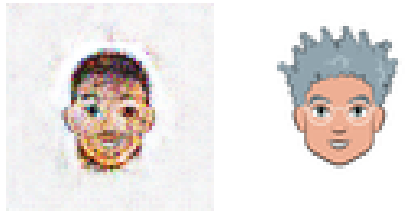
d coseno = 0.3499

ID 120 · GAN / real



d coseno = 0.2782

ID 163 · GAN / real



d coseno = 0.3098

ResNet18 ImageNet, 512 características normalizadas; vecino de menor distancia coseno entre 10 000 imágenes. Se observan diferencias de cabello, contorno o accesorios; sin copias casi idénticas evidentes en estas parejas.

La medida no certifica originalidad. ImageNet difiere del dominio de caricaturas; varios personajes comparten vecino y requieren revisión visual.

Selección honesta y reproducción comprobada

Selección: 10 / 200 = 5 %

Lote fijo: semilla 7070, 200 vectores guardados.
Criterios: rostros reconocibles, menos artefactos, diferencias en varios rasgos y revisión de vecinos.
ID128 se sustituyó por ID013 por diversidad. La selección de checkpoint usó las rejillas fijas.

Regeneración

Pesos de G, vectores exactos y batches originales de 32.
T4 / PyTorch 2.11.0+cu130: 10 PNG idénticos; error máximo 0.
CPU / PyTorch 2.13.0: 9 idénticos; ID024 con diferencia máxima de 1 nivel de intensidad.

Repositorio: seis notebooks, script de regeneración, README, configuraciones, historias, curvas, galería, vecinos y pesos del generador. No requiere volver a entrenar para producir los 10 PNG.

github.com/Jorge162017/GAN-DeepLearning

Reproducción exacta comprobada en el entorno CUDA registrado; no se garantiza igualdad bit a bit al cambiar hardware o versiones.

Lo aprendido y el caso más difícil de defender

Conclusiones y fallos

La GAN aprende estructura facial y estilo, pero conserva ruido, ojos deformados y contornos irregulares.
D domina gran parte del entrenamiento. Los experimentos no confirman una mejora consistente; el lote repite arquetipos.
La selección visual mejora la galería, pero puede ocultar parte de los fallos si no se declara.

Reflexión: personaje ID013

Es el caso más difícil de defender por compartir rostro frontal y cabello largo con su vecino, y por tener la menor distancia entre los 10: 0.2633.
Difiere en color y configuración de rasgos, pero eso no basta por sí solo para afirmar novedad. Sugiere recombinación de patrones del universo, con originalidad limitada y verificable solo parcialmente.

Límites: una sola semilla, evaluación visual, CNN de otro dominio y resolución 64 × 64. Siguiente mejora: repetir semillas y evaluar diversidad en todo el lote, antes de aumentar resolución.

Uso de IA declarado en README: planificación, programación y apoyo al análisis. Todas las imágenes finales provienen de la GAN entrenada por el equipo.

Matriz de evidencias

Evidencia	Diap.	Conclusión	Limitación
Universo y datos	2	Estilo definido; 10 000 datos y licencia citados.	Retratos; sin cuerpo ni ambiente generado.
Arquitectura y control	3-4	DCGAN explicable; un cambio por experimento.	Una semilla y presupuesto fijo.
Ruido fijo	5	Del ruido a rostros; variedad visible.	16 ejemplos no descartan colapso parcial.
Pérdida e hipótesis	6	Suavizado: menor confianza; mejora visual mixta.	Objetivos BCE distintos; no equivalencia directa.
Estabilización y curvas	7	D sigue dominando; checkpoint 15 elegido.	Menor pérdida no prueba mayor calidad.
Galería y selección	8, 10	10 PNG; selección 10/200 = 5 %.	Artefactos y repetición de arquetipos.
Vecinos cercanos	9	Sin copias casi idénticas evidentes en parejas.	CNN ImageNet no certifica originalidad.
Regeneración y reflexión	10-11	T4: error 0; ID013 es el caso más discutible.	Variación numérica fuera del entorno; novedad parcial.

Fuentes y código: README del repositorio